

— PROJETO DE SISTEMAS · CAMADA SEMÂNTICA DE IA

Helena Semantic Studio

Um estúdio de **observabilidade e qualidade** para uma
IA de BI conversacional em produção.

1.716

CONVERSAS REAIS

US\$ 13,43

CUSTO MEDIDO

3 / 3

FASES ENTREGUES

Autor: _____ · Disciplina: _____

Julho de 2026

Como confiar numa IA que é opaca, cara e imprevisível?

IMPREVISÍVEL

Não-determinística

A mesma pergunta pode gerar respostas diferentes a cada vez. Como se testa e se garante algo que não é reproduzível?

OPACA

Cara e sem visibilidade

Cada resposta gasta tokens e dinheiro, e não se enxerga o custo, a latência, nem *por que* a IA respondeu aquilo.

FRÁGIL

Degrada em silêncio

Mudou o prompt, alguém quebrou algo — e ninguém percebe até um usuário reclamar. Falta rede de segurança.

O assistente (a “Helena”) **já existia**. O que faltava era o **instrumento para governá-lo**: medir, auditar e melhorar de forma contínua.

Um oráculo determinístico e barato para auditar o LLM

IA de produção

A Helena responde com LLM

Poderosa, porém cara, não-determinística e opaca. É quem entrega valor ao usuário final.



Estúdio de qualidade


O Studio interpreta com regras

Sem LLM: normalização de texto + sinônimos. Barato, 100% reproduzível e auditável.

Quando os dois **discordam** → é uma **divergência**: um sinal automático de possível erro, que sobe para revisão humana.

É uma **avaliação cruzada**: o componente barato e verificável audita o componente caro e opaco — **sem precisar de um segundo LLM**.

Um ciclo fechado de melhoria contínua



↺ O golden set realimenta a etapa de auditoria: mexeu no assistente, os testes **pegam a regressão** antes do usuário.

Fluxo técnico: Usuário → banco do assistente (Postgres) → **ETL read-only** → banco do Studio → enriquecimento por regras → telas + curadoria → golden set.

Pipeline de coleta read-only

- **Read-only** — o Studio só lê o banco do assistente; nunca escreve nele.
- **Idempotente** — re-sincronizar não duplica turnos (chave única por mensagem).
- **Incremental (watermark)** — só traz o que é novo; um ciclo que falha retoma de onde parou.
- **Fail-safe de PII** — importa só chats de BI por whitelist; dados de RH/candidatos nunca entram.
- **Degradação graciosa** — fonte fora do ar não derruba o Studio; tenta no próximo ciclo.
- **Agendado** — sincroniza sozinho a cada 2 minutos, ou sob demanda.

Resultado real: 1.716 turnos e 263 conversas importados do banco de produção, sem duplicar, com o histórico completo de custo e feedback preservado.

Da pergunta em português à métrica de negócio

Exemplo real: “quanto moeu ontem por turno?” — o motor determinístico faz, passo a passo e sem LLM:

1 · NORMALIZA

texto

remove acentos, minúsculas,
tokeniza, tira stopwords

2 · CASA MÉTRICA

Moagem

sinônimo “moeu” → +0,5 de score

3 · PERÍODO

ontem

regra de data relativa

4 · AGRUPAMENTO

turno

dimensão de quebra

Cada sinal soma um **score de confiança**. O resultado é um “plano semântico” estruturado — **reproduzível e explicável**, ao contrário da caixa-preta do LLM.

Medir o que antes era invisível

CONVERSAS COLETADAS

1.716

em 263 sessões reais

CUSTO TOTAL (LLM)

US\$ 13,43

rastreado por domínio

LATÊNCIA P50 / P95

4,1 / 10,9_s

média de 4,8 s por resposta

TAXA DE ERRO

3,7%

respostas sem dado / com falha

FEEDBACK DOS USUÁRIOS

33 / 1

likes / dislikes

DOMÍNIO MAIS USADO

Agrícola

moagem, cana, ATR...

Tudo em uma tela: gráficos de **volume por dia**, custo por domínio e feedback — o painel de controle que a operação não tinha.

Divergência: quando a IA e o catálogo discordam

Pergunta real: *“Qual foi a disponibilidade de colhedoras antes de 2010?”*

ROTEAMENTO REAL DA HELENA

Agrícola

“colhedoras” → tratou como tema agrícola

vs.

LEITURA DO STUDIO (REGRAS)

Automotiva

catálogo classifica “disponibilidade de equipamentos” como automotiva

Conflito genuíno de catálogo, achado **automaticamente** — sem ninguém ler as 1.716 conversas. Exatamente o tipo de erro sutil que passa despercebido.

De conversa bruta a vocabulário curado

TURNOS ROTULADOS PELO STUDIO

590

o dado original só tinha 193 — cobertura **triplicada**

DIVERGÊNCIAS DETECTADAS

2

conflitos reais de catálogo

SUGESTÕES DE VOCABULÁRIO

304

termos reais para curadoria humana

Human-in-the-loop: das 304 sugestões há ruído (“foi”, “diga”), mas também **ouro** — como **“ATR”** (Açúcar Total Recuperável) e “gráfico”. Aprovar um sinônimo *melhora o motor na hora*; um bom caso vira **golden set** (teste de regressão).

Conceitos de computação aplicados

Engenharia de Dados	Pipeline ETL read-only · idempotência · watermark (sincronização incremental) · isolamento da fonte
Proc. de Linguagem Natural	Camada semântica (linguagem → métrica) · normalização (NFD, stopwords, tokenização) · casamento por sinônimos com score
Engenharia de Software	Arquitetura em camadas · TDD (teste antes do código) · <i>test doubles</i> (mock/fake) · tratamento de erro centralizado
LLMOps / Qualidade de IA	Observabilidade (custo, tokens, latência) · golden set p/ regressão · curadoria <i>human-in-the-loop</i> · detecção de divergência
Segurança & Privacidade	Filtro <i>fail-safe</i> de PII — dados sensíveis de candidatos de RH nunca são coletados

O que foi provado — e o que falta

Entregue e verificado

- 3 fases completas · 38 testes automatizados · build de produção OK
- Validado contra o banco **real**: 1.716 conversas, custo e feedback medidos
- Auditoria automática achou divergências reais de catálogo

Limitações & trabalhos futuros

- É uma **base técnica funcional** (protótipo), ainda sem autenticação
- Motor de regras é simples (regex + sinônimos) — gera ruído nas sugestões
- Evoluções: casamento por *embeddings*; comparar contra um baseline de LLM

Respostas às perguntas prováveis

“Qual é o diferencial / o que é novo?”

Não é o chatbot (esse já existia), e sim o **loop fechado de qualidade** em volta dele — e usar um oráculo determinístico barato para auditar um LLM.

“Por que não usar o próprio LLM para avaliar tudo?”

Um LLM avaliando outro é caro, lento e igualmente imprevisível — sem âncora confiável. O motor de regras é reproduzível e custa zero; ele não responde, **controla**.

“O que você provou que funciona?”

Dados reais: 1.716 conversas, US\$ 13,43 de custo medido, rotulagem triplicada (193 → 590) e divergências genuínas encontradas automaticamente.

— EM UMA FRASE

Um sistema de observabilidade e garantia de qualidade para uma IA de BI em produção.

Coleta as conversas reais, mede custo e desempenho, e usa um motor semântico determinístico para **auditar automaticamente** o que a IA respondeu — fechando um ciclo de melhoria contínua com curadoria humana.

medir

OBSERVABILIDADE

auditar

DIVERGÊNCIA

melhorar

CURADORIA + GOLDEN SET